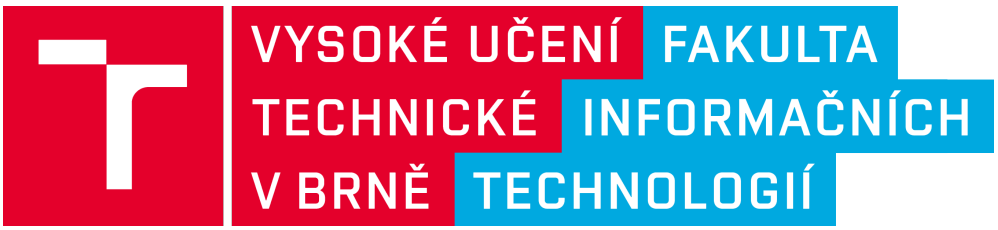

Projektová dokumentace

Implementace překladače imperativního jazyka IFJ22

Tým **xmoise01**, varianta **BVS**

6. prosince 2022

Nikita Moiseev	**(xmoise01)**	25 %
Maksim Kalutski	(xkalut00)	25 %
Elena Marochkina	(xmaroc00)	25 %
Nikita Pasynkov	(xpasyn00)	25 %

Obsah

1 Úvod

Cílem projektu bylo vytvořit program v jazyce C, který načte zdrojový kód zapsaný ve zdrojovém jazyce IFJ22, jenž je zjednodušenou podmnožinou jazyka PHP a přeloží jej do cílového jazyka IFJcode22 (mezikód).

Program funguje jako konzolová aplikace, které načítá zdrojový program ze standardního vstupu a generuje výsledný mezikód na standardní výstup nebo v případě chyby vrací odpovídající chybový kód.

2 Návrh a implementace

Projekt jsme sestavili z několika námi implementovaných dílčích částí, které jsou představeny v této kapitole. Je zde také uvedeno, jakým způsobem spolu jednotlivé dílčí části spolupracují.

2.1 Lexikální analýza

Při tvorbě překladače jsme začali implementací lexikální analýzy. Hlavní funkce této analýzy je `get_next_token`, pomocí níž se čte znak po znaku ze zdrojového souboru a převádí na strukturu `token`, která se skládá z typu a hodnoty. Typy tokenu jsou `EOF`, speciální znaky, speciální závorky PHP, identifikátory, klíčová slova, datové typy a také aritmetické, relační a logické operátory a operátor přiřazení a ostatní znaky, které mohou být použity v jazyce IFJ2022. Hodnota atributu je `value`. Pokud je typ tokenu identifikátor, pak bude atribut daný identifikátor, když by byl typ tokenu klíčové slovo, přiřadí atributu dané klíčové slovo, pokud číslo, atribut bude ono číslo. S takto vytvořeným tokenem poté pracují další analýzy.

Celý lexikální analyzátor je implementován jako deterministický konečný automat podle předem vytvořeného diagramu 6. Konečný automat je v jazyce C jako jeden nekonečně opakující se `switch`, kde každý případ `case` je ekvivalentní k jednomu stavu automatu. Pokud načtený znak nesouhlasí s žádným znakem, který jazyk povoluje, program je ukončen a vrací chybu 1 `LEXICAL ERROR CODE 1`. Jinak se přechází do dalších stavů a načítají se další znaky, dokud nemáme hotový jeden token, který potom vracíme a ukončíme tuto funkci.

2.2 Syntaktická analýza

Nejdůležitější částí celého programu je syntaktická analýza. Syntaktická analýza je implementována v souboru `syntax_analyzer.c`, a její rozhraní pro implementaci v `syntax_analyzer.h`.

Syntaktická analýza je implementována pomocí rekurzívního sestupu na základě LL gramatiky - Tabulka 2. Syntaktický analyzátor zpracovává všechny části LL gramatiky na výrazy podle pravidel v LL - tabulce - Tabulka 3. Úkolem syntetického analyzátoru je sestavit abstraktní syntaktický strom na základě seznamu tokenů. Strom je postaven tak, že je nastavena priorita operací a ve výsledku můžeme načtením tohoto stromu spustit kód v požadovaném pořadí. Pokud je nalezena chyba, překladač dokončí kontrolu, vymaže alokovanou paměť a zobrazí chybovou hlášku na standartní chybový vstup. Syntaktický analyzátor nijak neupravuje tokeny a všechny chyby jsou detekovány až v průběhu sémantické analýzy. Po vytvoření abstraktního syntaktického stromu syntaktický analyzátor přejde do další fáze sémantické analýzy.

Príklady stromu pro syntaktickou analýzu jsou uvedeny na obrázkéch 1- 4.

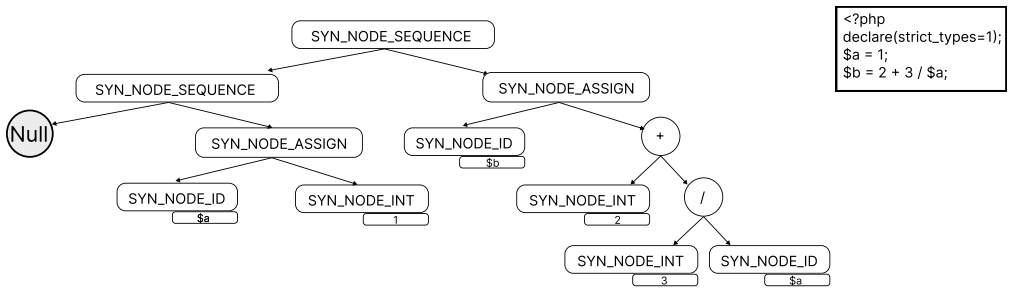

Obrázek 1: Abstraktní syntaktický strom přiřázení proměnných

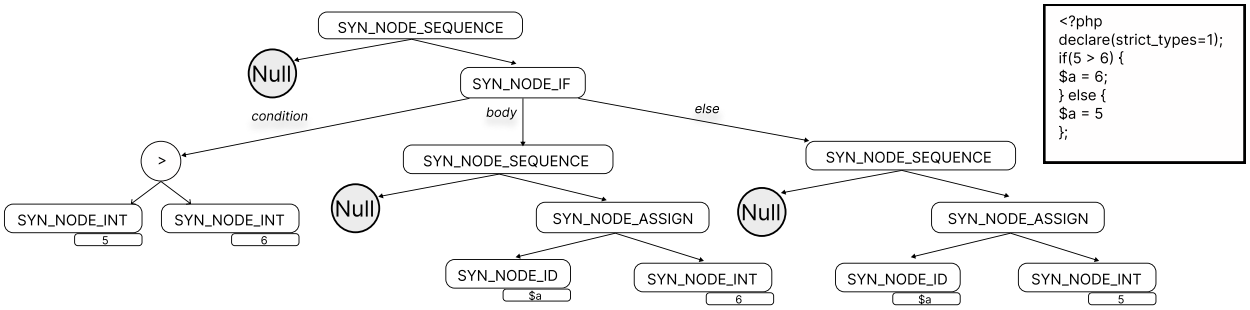

Obrázek 2: Abstraktní syntaktický strom větvení

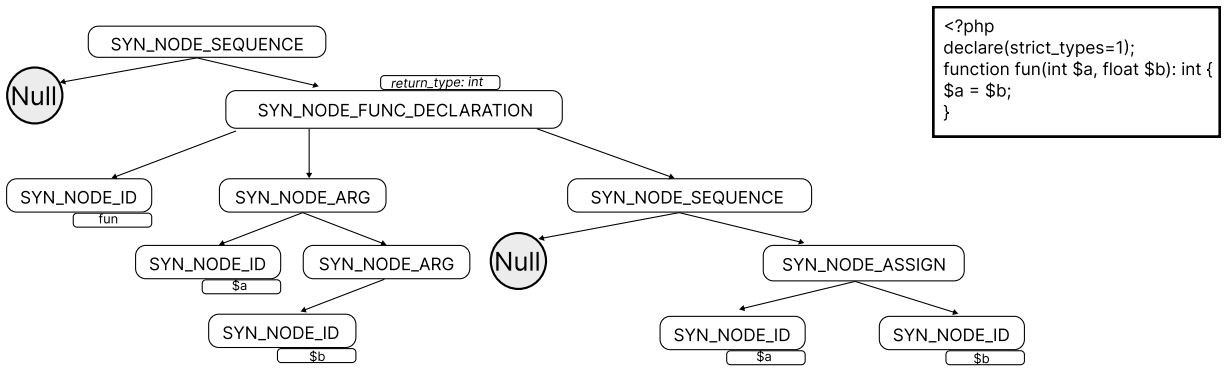

Obrázek 3: Abstraktní syntaktický strom deklarací funkcí

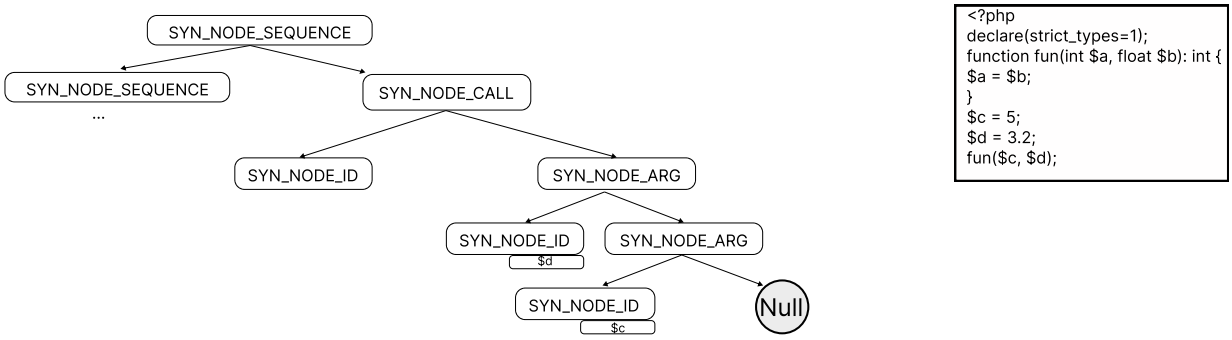

Obrázek 4: Abstraktní syntaktický strom volání funkcí

2.3 Sémantická analýza

Sémantická analýza je implementována v souboru `semantic_analyzer.c` a její rozhraní pro implementaci v `semantic_analyzer.h`.

Sémantický analyzátor pracuje s abstraktním syntaktickým stromem, který vytvořil syntaktický analyzátor. Úkolem sémantického analyzátoru je kontrola sémantické správnosti zdrojového programu: kontrola deklarací, datových typů, seznamů parametrů apod. a to pomocí kontroly datových typu.

K tomu využívá datové struktury a funkce pro sémantické kontroly. Pokud při kontrole je nalezena chyba, překladač dokončí kontrolu, vymaže alokovanou paměť a zobrazí chybovou hlášku na standartní chybový vstup.

V souborech `symtable.c` a `symtable.h` je uložená tabulka symbolů.

Tabulka symbolů je binární vyhledávací strom, který obsahuje informace o všech identifikátorech kódu. Tabulka symbolů se skládá jak z globálního stromů (pro všechny globální proměnné), tak z lokálních stromů (pro argumenty a lokální proměnné funkcí).

Tabulka symbolů je uložena a okamžitě použita v sémantické analýze a slouží ke kontrole, zda daný identifikátor existuje a zda souhlasí jeho datový typ, případně návratová hodnota.

Příklad stromu pro tabulku symbolů je uveden na obrázku 5.

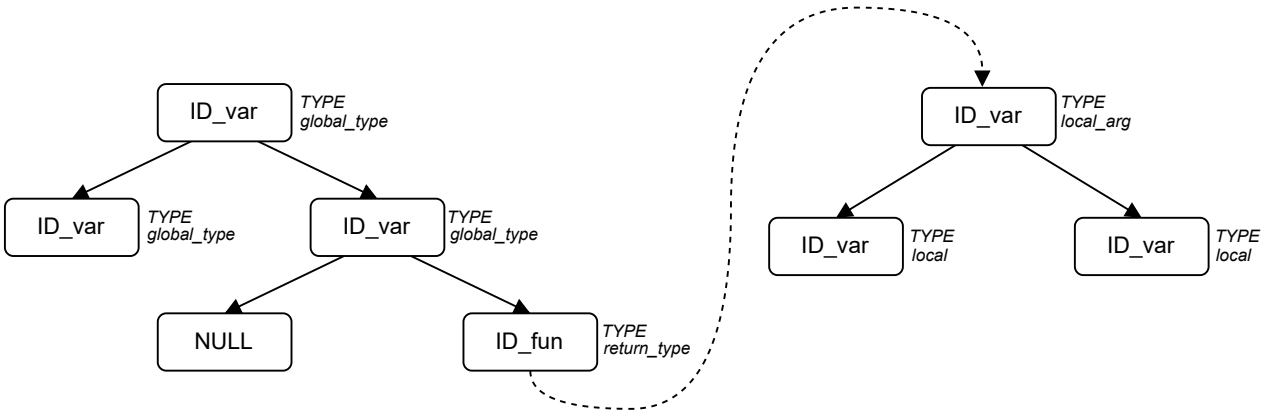

Obrázek 5: Tabulka symbolů

2.4 Optimalizáce kódu

Optimalizáce kódu je implementováné v souboru `optimiser.c` a jeho rozhraní pro implementaci v souboru `optimiser.h`.

Optimalizáce kódu pracuje s abstraktním syntaktickým stromem a mění ho.

Optimalizátor kódu se spustí ihned po sémantické analýze a před vygenerováním kódu.

Optimalizátor kódu provádí následující hlavní akce:

1. Optimalizuje matematické výrazy (například `$a = 5 + 9/3; -> $a = 8;`)

2. Přiřazování a změna hodnoty proměnné během programu
3. Optimalizuje nedosažitelné smyčky while a if
4. Odstraňuje nepoužívané proměnné

2.5 Generování cílového kódu

Generování cílového kódu je implementováné v souboru `code_generator.c` a jeho rozhraní pro implementaci v `code_generator.h`. Generování kódu pracuje s abstraktním syntaktickým stromem po optimalizáce kódu.

Generování cílového kódu znamená generování mezikódu IFJcode22. Kód je generován na standardní výstup po dokončení všech analýz.

Na začátku generování jsou inicializovány potřebné datové struktury (které jsou na závěr uvolněny), vygenerována hlavička mezikódu, která zahrnuje potřebné náležitosti pro korektní interpretaci mezikódu a skok do hlavního těla programu. Poté jsou vygenerovány vestavěné funkce, které jsou zapsány přímo v jazyce IFJcode22.

Každá funkce mezikódu IFJcode22 je tvořena návěštím ve tvaru `$generate_funkce`.

Pak se spouští parser syntaktického stromu, dokud není nalezen jeden z uzlů: `SYN_NODE_ASSIGN`, `SYN_NODE_KEYWORD_IF`, `SYN_NODE_KEYWORD_WHILE`, `SYN_NODE_FUNCTION_DECLARATION`, `SYN_NODE_CALL`. Pro každý z uzlů jsou spuštěny různé funkce generování kódu.

Generování výrazů

Jednoduché výrazy jsou zpracovávány optimalizátorem a generovány pomocí jednoho příkazu. U složitých výrazů, které optimalizátor nerozpozná, lze k výrazům přidat další proměnné pro provádění výpočtů.

Generování cyklů

Pokud je proměnná deklarována ve cyklu, bylo nutné ji před začátkem cyklu definovat.

Generování funkcí

Pro funkce a jejich proměnné byl vytvořen lokální rámec. Pokud nejsou v kódu volány vestavěné funkce, generátor kódu je nevygeneruje.

3 Práce v týmu

3.1 Způsob práce v týmu

Na projektu jsme začali pracovat na začátku října. Práci jsme si dělili postupně, tj. neměli jsme od začátku stanovený kompletní plán rozdělení práce. Na dílčích částech projektu pracovali většinou dvojice členů týmu.

3.1.1 Vývoj

Veškerá naše práce byla rozdělena do sprintů, každý trval týden. Během sprintu musel každý jednotlivý člen týmu splnit určité úkoly.

Pro správu souborů projektu jsme používali verzovací systém Git. Jako vzdálený repositář jsme používali *repozitář na GitHubu*.

Git nám umožnil pracovat na více úkolech na projektu současně v tzv. větvích. Většinu úkolů jsme nejdříve připravili do větve a až po otestování a schválení úprav ostatními členy týmu jsme tyto úpravy začlenili do hlavní vývojové větve.

Pro testování jsme použili knihovnu pro testování jednotek *googletest*.

3.1.2 Komunikace

Komunikace mezi členy týmů probíhala převážně osobně nebo prostřednictvím aplikace Telegram.

V průběhu řešení projektu jsme měli i osobní setkání každý týden, kde jsme probírali a řešili problémy týkající se různých částí projektu. Pro plánování úkolů jsme použili webovou aplikaci *Notion*.

3.2 Rozdělení práce mezi členy týmu

Práci na projektu jsme si rozdělili rovnoměrně s ohledem na její složitost a časovou náročnost. Každý tedy dostal procentuální hodnocení 25 %. Tabulka 1 shrnuje rozdělení práce v týmu mezi jednotlivými členy.

Člen týmu	Přidělená práce
Nikita Moiseev	vedení týmu, organizace práce, dohlížení na provádění práce, konzultace, kontrola, lexikální analýza, syntaktická analýza, optimalizace kódu, testování, dokumentace
Maksim Kalutski	generování cílového kódu, testování, dokumentace
Elena Marochkina	implementace tabulky symbolů, syntaktická analýza, sémantická analzya, testování, dokumentace
Nikita Pasynkov	lexikální analýza, syntaktická analýza, sémantická analzya, testování, dokumentace

Tabulka 1: Rozdělení práce v týmu mezi jednotlivými členy

4 Závěr

Náš tým jsme měli sestaven brzy a pracovalo se nám společně velmi dobře.

V průběhu vývoje jsme se potýkali s menšími problémy týkajícími se nejasností v zadání, ale tyto jsme vyřešili díky fóru k projektu. Správnost řešení jsme si ověřili pomocí Google testy a pokusnímu odevzdání, díky čemuž jsme byli schopni projekt ještě více odladit.

Tento projekt nám celkově přinesl spoustu znalostí ohledně fungování překladačů, prakticky nám objasnil probíranou látku v předmětech IFJ a IAL a přinesl nám zkušennosti s projekty tohoto rozsahu.

A Diagram konečného automatu specifikující lexikální analyzátor

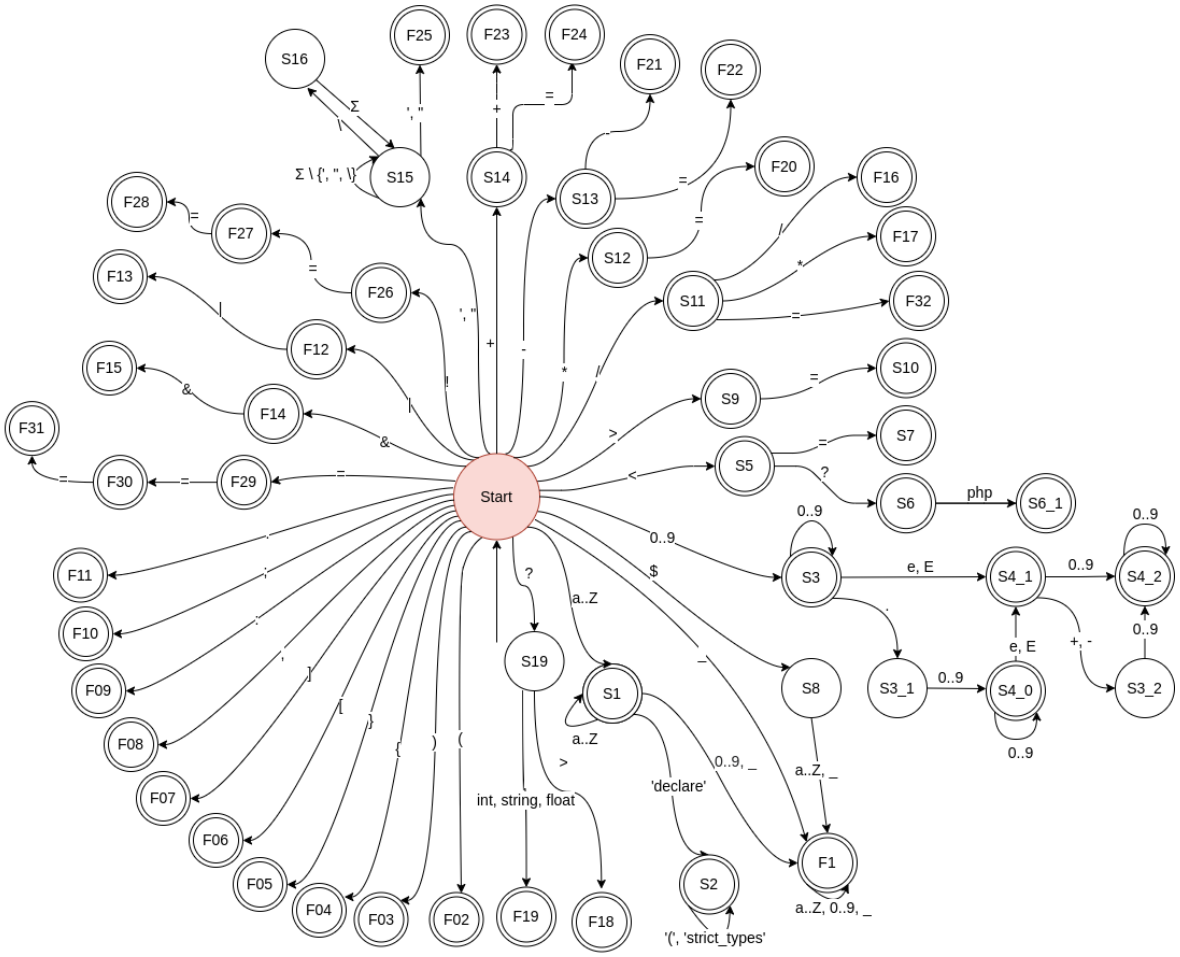

S1: keyword and ID state
S2: declare state
S3: integer state
S3_1, S3_2: float middle state
S4_0, S4_1, S4_2: float state
S5: less
S6: open php bracket
S6_1: open php bracket
S7: less or equal
S8: identifier state
S9: greater
S10: greater or equal
S11: divide
S12: multiply
S13: minus
S14: plus
S15: string state
S16: string escape state
S17: not
S18: not equal
S19: optional question mark

F01: identifier
F02: left parenthesis
F03: right parenthesis
F04: left curly brackets
F05: right curly brackets
F06: left square brackets
F07: right square brackets
F08: comma
F09: colon
F10: semicolon
F11: concatenation
F12: bitwise or
F13: logical or
F14: bitwise and
F15: logical and
F16: comment

F17: multiline comment
F18: close php bracket
F19: optional data type
F20: multiply assign
F21: decrement
F22: minus assign
F23: increment
F24: plus assign
F25: string
F26: not
F27: not equal
F28: typed not equal
F29: assign
F30: equal
F31: typed equal
F32: divide assign

Obrázek 6: Diagram konečného automatu specifikující lexikální analyzátor

B LL – gramatika

1. <prog> -> <?php <declare> <f-dec-stats> <stat-list> ?>
2. <prog> -> <? <declare> <f-dec-stats> <stat-list> ?>
3. <f-dec-stats> -> <f-dec-stat>
4. <f-dec-stats> -> <f-dec-stat> <f-dec-stats>
5. <f-dec-stat> -> function ID (<f-args>) : <f-type> { <stat-list> }
6. <f-dec-stat> -> function ID (<f-args>) { <stat-list> }
7. <f-type> -> int
8. <f-type> -> float
9. <f-type> -> string
10. <f-type> -> void
11. <f-type> -> ε
12. <f-args> -> <f-arg>
13. <f-args> -> <f-arg>, <f-args>
14. <f-args> -> ε
15. <f-arg> -> <arg-type> ID
16. <arg-type> -> int
17. <arg-type> -> float
18. <arg-type> -> string
19. <arg-type> -> ε
20. <stat> -> ID = <expr> ;
21. <stat> -> ID = ID (<args>) ;
22. <stat> -> ID (<args>) ;
23. <stat> -> return <expr> ;
24. <stat> -> if (<expr>)
25. <stat> -> if (<expr>) <stat> else <stat>
26. <stat> -> while (<expr>) <stat>
27. <stat> -> { <stat-list> }
28. <args> -> <arg>
29. <args> -> <arg>, <args>
30. <arg> -> <term>
31. <arg> -> ε
32. <term> -> int
33. <term> -> float
34. <term> -> string
35. <term> -> NULL
36. <term> -> ID
37. <stat-list> -> <stat> <stat-list>
38. <stat-list> -> ε
39. <expr> -> EXPR <expr>
40. <expr> -> ID (<args>)
41. <expr> -> ε
42. <declare> -> declare(strict-types = 0) ;
43. <declare> -> declare(strict-types = 1) ;

Tabulka 2: LL – gramatika řídící syntaktickou analýzu

C LL – tabulka

	<?php	<?	declare	function ID	ID	int	float	string	void	null	=	:	,	;	(	)	if	else	while	{	}	?>	return
<prog>	1	1																					
<declare>			2																				
<f-dec-stats>				3																			
<f-dec-stat>				4																			
<f-args>						5	5	5								6							
<f-arg>						7	7	7					8										
<f-type>						9	9	9	9														
<arg-type>						10	10	10															
<stat>					11												11	12	11	11			11
<stat-list>					13												13		13	13	14		13
<args>					15	15	15	15		15						16							
<arg>					17	17	17	17		17			18										
<term>					19	19	19	19		19													
<expr>					20									21		22							

Tabulka 3: LL – tabulka použitá při syntaktické analýze

D Precedenční tabulka

	+ -	* /	<>	(	)	id	$
+ -	>	<	>	<	>	<	>
* /	>	>	>	<	>	<	>
<>	<	<	0	<	>	<	>
(	<	<	<	<	=	<	0
)	>	>	>	0	>	0	>
id	>	>	>	0	>	0	>
$	<	<	<	<	0	<	End

+ - – aritmetické operátory + a -
* / – aritmetické operátory * a /
<> – relační operátory ==, !=, <, >, <=, >=
(– levá závorka
) – pravá závorka
id – identifikátor
$ – konec vstupu

Tabulka 4: Precedenční tabulka použitá při syntaktické analýze